



DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

Trabajo Práctico II

subtitulo del trabajo

Organización del Computador II
Segundo Cuatrimestre de 2014

Integrante	LU	Correo electrónico
Alejandro Mignanelli	609/11	minga_titere@hotmail.com
Franco Negri	893/13	franconegri2004@hotmail.com
Federico Suárez	610/11	elgeniofederico@gmail.com



Facultad de Ciencias Exactas y Naturales
Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja)

Intendente Güiraldes 2160 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (54 11) 4576-3359

<http://www.fcen.uba.ar>

Resumen

En el presente trabajo se describe la problemática de procesar información de manera eficiente cuando los mismos requieren:

1. Transferir grandes volúmenes de datos.
2. Realizar las mismas instrucciones sobre un set de datos importante.

Índice

1. Objetivos generales	3
2. Preambulo	4
2.1. Calidad de las Mediciones	4
3. Experimentación	5
3.1. Desensamblado de código C y Optimización	5
4. Cropflip	6
4.1. Diferencias de performance en Cropflip	6
4.1.1. Resultados	6
4.1.2. Conclusiones	6
4.2. cpu vs. bus de memoria en Cropflip	7
4.2.1. Resultados	7
4.2.2. Conclusiones	7
5. Sierpinski	8
5.1. Idea general del algoritmo	8
5.2. Diferencias de performance en Sierpinski	9
5.2.1. Resultados	10
5.2.2. Conclusiones	10
5.3. CPU vs. Bus de memoria en Sierpinski	11
5.3.1. Resultados	11
5.3.2. Conclusiones	11
6. Bandas	12
6.1. Idea general del algoritmo	12
6.2. Diferencias de performance en Bandas	13
6.2.1. Resultados	14
6.2.2. Conclusiones	14
6.3. Saltos condicionales	15
6.3.1. Resultados	15
6.3.2. Conclusiones	15
6.4. Motion Blur	16
6.5. Idea general del algoritmo	16
6.6. Diferencias de performance en Motion Blur	17
6.6.1. Resultados	18
6.6.2. Conclusiones	18
7. Conclusiones y trabajo futuro	19

1. Objetivos generales

El objetivo de este Trabajo Práctico es mostrar las variaciones en la performance que suceden al utilizar instrucciones SIMD en comparación con código C con diversos grados de optimización realizados por el compilador cuando se manejan grandes volúmenes de datos que requieren un procesamiento similar.

Para ello se realizarán distintos experimentos sobre cuatro filtros de fotos, Cropflip, Bandas, Sierpinski y Motion Blur, tanto en código assembler, que aproveche las instrucciones SSE brindadas para los procesadores de arquitectura Intel, como en código C, al que se le aplicarán los distintos flags de optimización -O0 (predeterminado), -O1, -O2 y -O3.

El primer filtro, Cropflip, se utilizará para mostrar cuanto mejora la performance al utilizar los registros XMM para transferir grandes cantidades de información.

El segundo, tercer y cuarto filtro, se centrarán en la variación de performance (en comparación al código en C) al utilizar instrucciones SIMD, no sólo para transferir grandes volúmenes de datos sino también para procesarlos en forma paralela, es decir, realizar diversos cálculos (sumas, multiplicaciones, divisiones) tanto en representación de enteros como punto flotante.

2. Preambulo


2.1. Calidad de las Mediciones

Para este experimento vamos a ver cómo se pueden ver afectados nuestros algoritmos frente a diversos factores de ruido e interferencias que podrían alterar nuestras mediciones.

Para este experimento se utilizó un procesador Intel Atom, de 2 núcleos a 1.6 GHZ con Hyper-Threading, por lo que la cantidad de núcleos lógicos asciende a 4. Por otro lado, para que las pruebas sean mas concisas y exactas, se deshabilitó el scaling dinamico del CPU, ya que esto podría generar ruido innecesario en nuestras mediciones.


Procedimos a tomar 1000 mediciones para cada una de las versiones del cropflip, tanto con 4 loops corriendo en paralelo como sin los mismos y los promediamos para obtener un valor aproximado de cuanto tarda en correr cada uno de los algoritmos.

Lo que se obtiene son los siguientes resultados:



Vemos que con loops, el desvío estandar se vuelve incontrolable, a tal punto que sería imposible sacar ninguna conclusión de los datos obtenidos. Ahora para intentar mejorar un poco las mediciones, quitamos los 200 valores mas grandes y los 200 valores mas chicos (estos van a ser nuestros outliers).

Volvemos a graficar:



De esta manera logramos obtener valores mucho mas razonables para el desvío estandar.

De este ultimo grafico ademas podemos observar que los loops afectan de manera diferente a los algoritmos, el codigo de C sin optimizar aumenta su tiempo de ejecución en un 25 %, mientras que el codigo de assambler no varía en lo mas minimo.

Finalmente se determina que para cada experimento en el presente informe, se tomaran 1000 mediciones sin loops corriendo y quitando los outliers antes mencionados.

3. Experimentación

3.1. Desensamblado de código C y Optimización

Comenzamos analizando el código de Cropflip realizado en C.

Este básicamente solo mueve datos de un lugar de la RAM a otros, sin afectar mayormente la imagen.

Realizamos un objdump para ver el código que genera el compilador gcc. Al desensamblar el código pudimos observar, primero que nada, que C guarda todos los parámetros en la pila y además está escribiendo en memoria todas las variables locales utilizadas, lo cual es innecesario ya que pueden ser almacenadas en registros.

También puede observarse que C utiliza saltos incondicionales, lo que puede sugerir que intenta sacar provecho al sistema de predicción de saltos.

Ademas C genera, luego de la función, un montón de secciones que comienzan con debug.xxx. Estas secciones sirven para ser interpretadas por GDB u otros debuggers.

Como ya dijimos, el código podría optimizarse para no realizar tantos accesos a memoria innecesarios guardando variables locales por ejemplo en registros, lo cual disminuiría el tiempo de ejecución.

Luego de esto, procedemos a compilar el código utilizando el flag -O1, y nuevamente realizamos un objdump para ver el código desensamblado. Se observa que ahora el mismo solo realiza los accesos a memoria mínimos indispensables, utilizando los registros para guardar los datos. Además el código es más compacto, y resulta mas claro de leer. Asimismo precalcula los valores que serán utilizados muchas veces, lo que aumenta la performance, principalmente en casos de instancias grandes.

Los otros flags de optimización son -O2, -O3, -Og, -Os, -Ofast. También podemos encontrar los flags -msse, -msse2, -msse3, -mmmx, -m3dnow, pero al intentar compilar con varios de ellos vimos que gcc no utilizó instrucciones SIMD.

De las muchas optimizaciones que C puede realizar, tomamos tres para ejemplificar: -foptimize-sibling-calls, -finline-small-functions, -fmerge-constants.

La optimizacion -foptimize-sibling-calls, sirve para optimizar las funciones con recurcion a la cola. Por otra parte -finline-small-functions integra funciones a las funciones que las llaman cuando el cuerpo de la función es menor que la cantidad de instrucciones necesarias para llamarla, resultando en un codigo de menor tamaño. Por ultimo -fmerge-constants intenta mergeare constantes identicas entre las distintas unidades de compilación.

4. Cropflip

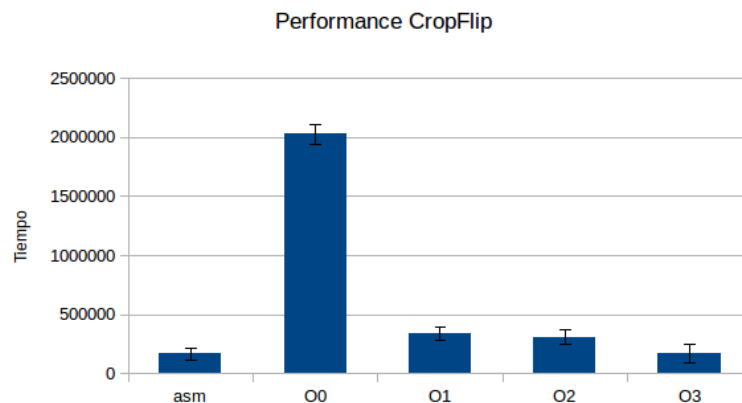
4.1. Diferencias de performance en Cropflip

En el siguiente experimento se medirán las performances tanto de nuestro algoritmo en assembler, implementado para sacar provecho de las instrucciones SSE de Intel, como una versión alternativa hecha en C con diversos grados de optimización a cargo del compilador.

El algoritmo de Cropflip en assembler es muy sencillo. Simplemente movemos 128-bits de la imagen a un xmm y de allí al destino, que previamente ha sido seteado para colocar los bits en el lugar correcto. De esta manera, podremos mover de una sola vez, 16 bytes, lo que corresponde a 4 píxels de la imagen.

Dado que la cantidad de columnas es siempre múltiplo de 4, o sea, siempre tenemos 4 bytes para tomar, no es necesario chequear otros casos borde.

Lo obtenido en los tests puede verse en el siguiente gráfico:



4.1.1. Resultados

Se percibe en el gráfico que la version SIMD del algoritmo de cropflip y la version C con mayor grado de optimización son muy parecidas en promedio, aunque la varianza del codigo C es levemente mayor la del primero. Por otro lado, el programa SIMD tiene una mayor performance a las optimizaciones O1 y O2, y la comparación con O0 muestra que en promedio, es más de 8 veces más rápido.

4.1.2. Conclusiones


Una de las razones por las que el codigo optimizado a nivel 3 puede obtener tan buenos resultados como los de SIMD, es que al optimizar con este nivel se activa un flag `fipa-cp-clone` que permite hacer algo llamado `interprocedural constant propagation`, que segun entendemos intenta paralelizar el codigo, o alguna otra optimización del codigo que lo hace extremadamente performante incluso sin utilizar SIMD. Aun asi, prestandole mas atención al desvio estandar, pareciera que este codigo tiene una mayor variabilidad que nuestro codigo en assembler, asi que aun asi, nuestro codigo pareciera tener alguna ventaja sobre el creado en C.

4.2. cpu vs. bus de memoria en Cropflip

Para este experimento lo que hicimos fue agregar instrucciones aritméticas por un lado y instrucciones de lectura-escritura por otro para ver como influía esto en el tiempo de ejecución de nuestro código en ensamblador.

Para eso agregamos 4, 8 y 16 instrucciones de lectura-escritura por un lado y 4, 8 y 16 instrucciones aritméticas entre registros en el loop principal del código ensamblador y comparamos las performance entre sí y con la versión original.

Lo que obtuvimos puede verse en el siguiente gráfico:



4.2.1. Resultados

Lo que vemos en este gráfico es que, si bien al agregar tanto operaciones aritméticas como operaciones de memoria, el tiempo aumenta, al comparar la misma cantidad de operaciones aritméticas contra operaciones de lectura-escritura (Mas notoriamente si se comparan entre sí el código con 16 operaciones aritméticas contra el código con 16 operaciones de lectura escritura), las segundas producen un mayor incremento en el tiempo de ejecución del algoritmo.

4.2.2. Conclusiones

Lo obtenido en los resultados era de esperar ya que es sabido que el cuello de botella del modelo Bon-Newman y en las arquitecturas modernas, ocurre con los accesos a memoria. En otras palabras, de aquí se puede comprobar de manera empírica que para el procesador es mas costoso acceder a memoria que realizar operaciones lógicas, de ahí la diferencia de tiempos que puede observarse.

5. Sierpinski

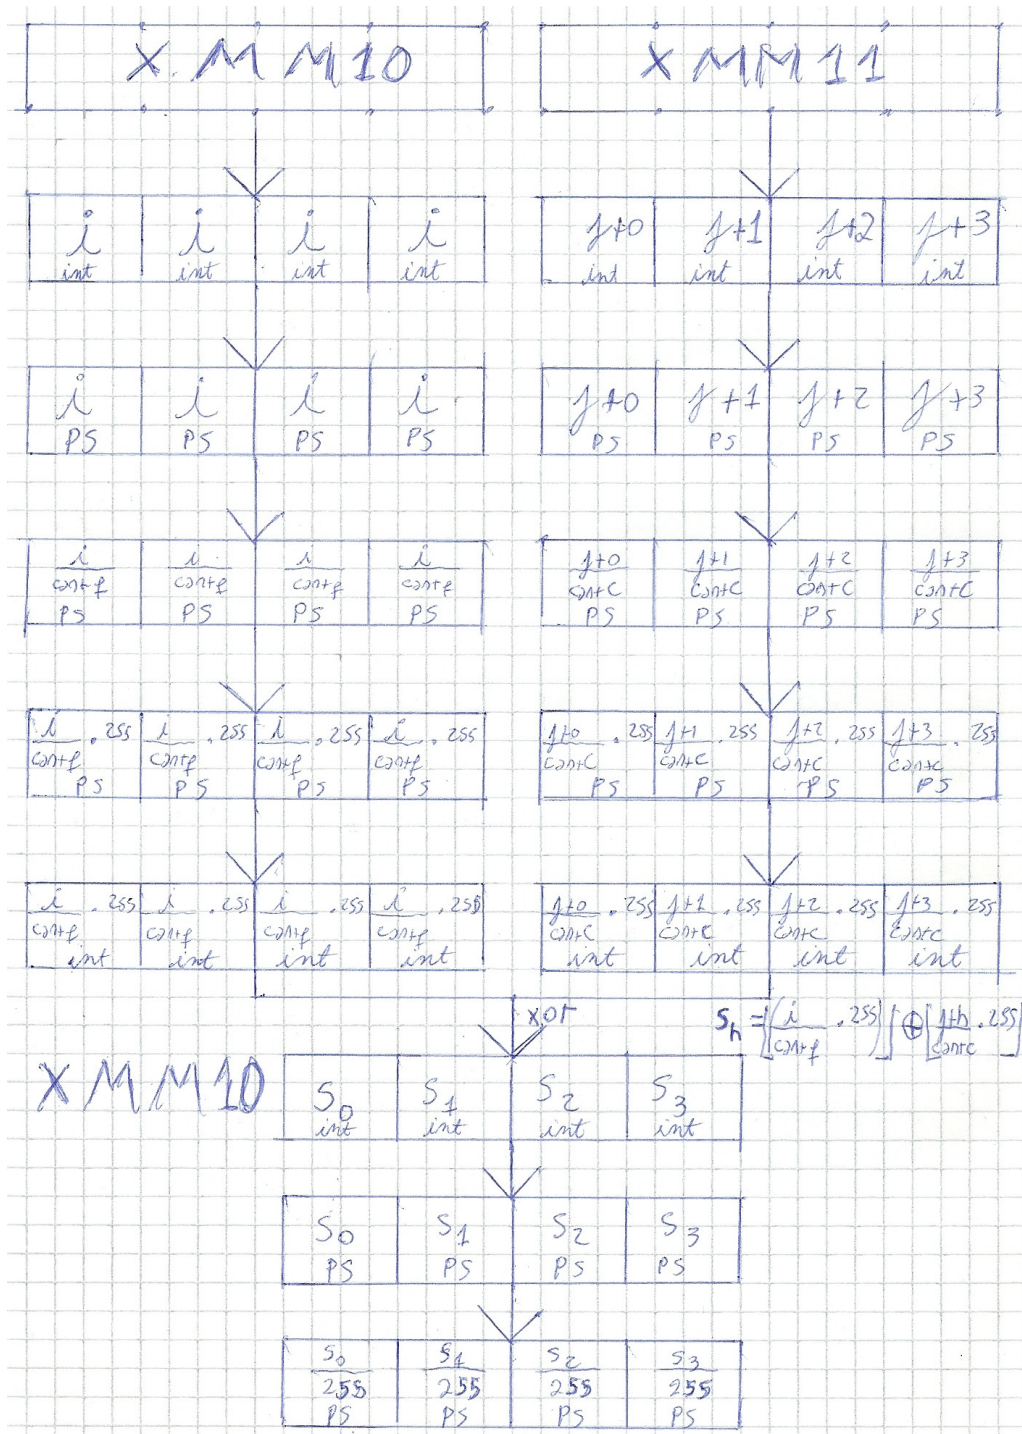
5.1. Idea general del algoritmo

Comenzaremos esta sección describiendo la idea tras el algoritmo de Sierpinski. En este caso, el algoritmo ya es un poco más complejo. Necesitamos calcular para cada píxel un coeficiente diferente, que dependerá de la posición (i, j) de cada píxel.

Luego para poder paralelizar de alguna manera el algoritmo en C y sacar provecho a los registros xmm, es necesario calcular 4 coeficientes a la vez y multiplicárselos a sus respectivos píxeles.

Luego la idea del algoritmo será algo así:

Al comenzar el ciclo, leemos 4 píxeles y los guardamos en un registro xmm. Luego, calculamos el coeficiente para cada píxel de forma paralela como se muestra en el dibujo.




Una vez obtenidos los coeficientes, sólo nos resta multiplicar a cada uno por el píxel correspondiente. Como debemos multiplicar dicho coeficiente por cada byte de cada píxel, primero deberemos desempaquetar los datos de tal manera que nos queden 4 registros xmm, uno para cada píxel, que cada uno contenga todos los bytes del píxel asociado en el orden original. A continuación, nos toca convertir todo a punto flotante para poder realizar la multiplicación. Además necesitaremos broadcastear el coeficiente de cada píxel en un registro xmm para así efectivamente multiplicarlo por cada componente del píxel. [ACÁ NO SÉ SI IRÍA DIBUJO DE CÓMO SE HARÍA ESTA MULTIPLICACIÓN, Y EN ESE CASO NO SÉ SI ESTARÍA DE MÁS DEJAR LA ANTERIOR EXPLICACIÓN] Después de terminar con las multiplicaciones, convertimos a entero nuevamente y empaquetamos todo para finalmente moverlo al destino.

- En la sección data guardamos una constante con el valor 255 broadcasteado en punto flotante.
- Previo al ciclo, guardamos este valor en un registro.
- Ya dentro del ciclo, leemos 4 píxels y los guardamos en un xmm.
- A continuación calculamos de manera paralela para cada píxel el coeficiente correspondiente.
- Primero, realizamos la división de i por la cantidad de filas y j por la cantidad de columnas, para la cual previamente pasamos de entero a punto flotante.
- Multiplicamos ambos valores por 255 y luego convertimos a entero con truncamiento.
- Realizamos un xor entre ambos y despues, volvemos a convertir a punto flotante para dividir por 255.
- Ya con los coeficientes calculados, solo nos resta multiplicar cada uno por el píxel correspondiente.
- Para ello desempaquetamos cada byte de cada píxel leído a word, y luego de word a dword, para así convertirlo a punto flotante.
- Una vez hecha la conversión, broadcasteamos cada coeficiente para poder multiplicarlo por el píxel correspondiente.
- Luego convertimos a entero nuevamente y empaquetamos todo de dword a word y de word a byte.
- Y finalmente movemos los píxels procesados al destino.

5.2. Diferencias de performance en Sierpinski

Los resultados comparativos de performance para este algoritmo comparado con uno desarrollado en C fueron los siguientes:



5.2.1. Resultados

Puede verse que en este caso, nuestro código en ensamblador, que toma y calcula de a 4 píxeles utilizando instrucciones SIMD tiene, en promedio, una mejor performance que los demás. En el gráfico puede notarse que este código es aproximadamente dos veces más rápido que la versión de C con O3, más de tres veces más rápido que O2 y O1 y más de 7 veces más veloz que O0, todo esto en promedio. El desvío estándar en este caso es tan pequeño que casi no puede verse en el gráfico.


5.2.2. Conclusiones

De lo que podemos observar, concluimos que en este caso, paralelizar los datos y operar sobre ellos resulta en un incremento de la performance incluso superior al código en C con mayor grado de optimización.

5.3. CPU vs. Bus de memoria en Sierpinski

Realizamos el mismo experimento que hicimos para cropflip, es decir, agregamos instrucciones aritméticas y de lectura escritura al código ensamblador para medir su desempeño.

Tomando el promedio y graficando los valores obtenidos:



5.3.1. Resultados

Nuevamente, como es de esperar al agregar operaciones, tanto aritméticas como de lectura-escritura, el tiempo de ejecución aumenta. También, como en el caso anterior, al comparar entre agregar un número de operaciones aritméticas y agregar el mismo número de operaciones de lectura-escritura, las operaciones de lectura escritura, son más caras para el procesador.

5.3.2. Conclusiones

Nuevamente podemos llegar a la misma conclusión que antes, el cuello de botella se encuentra en el tiempo que el procesador tarda en buscar datos a memoria. Incluso implementando técnicas avanzadas como caché y ejecución fuera de orden, puede notarse la diferencia.

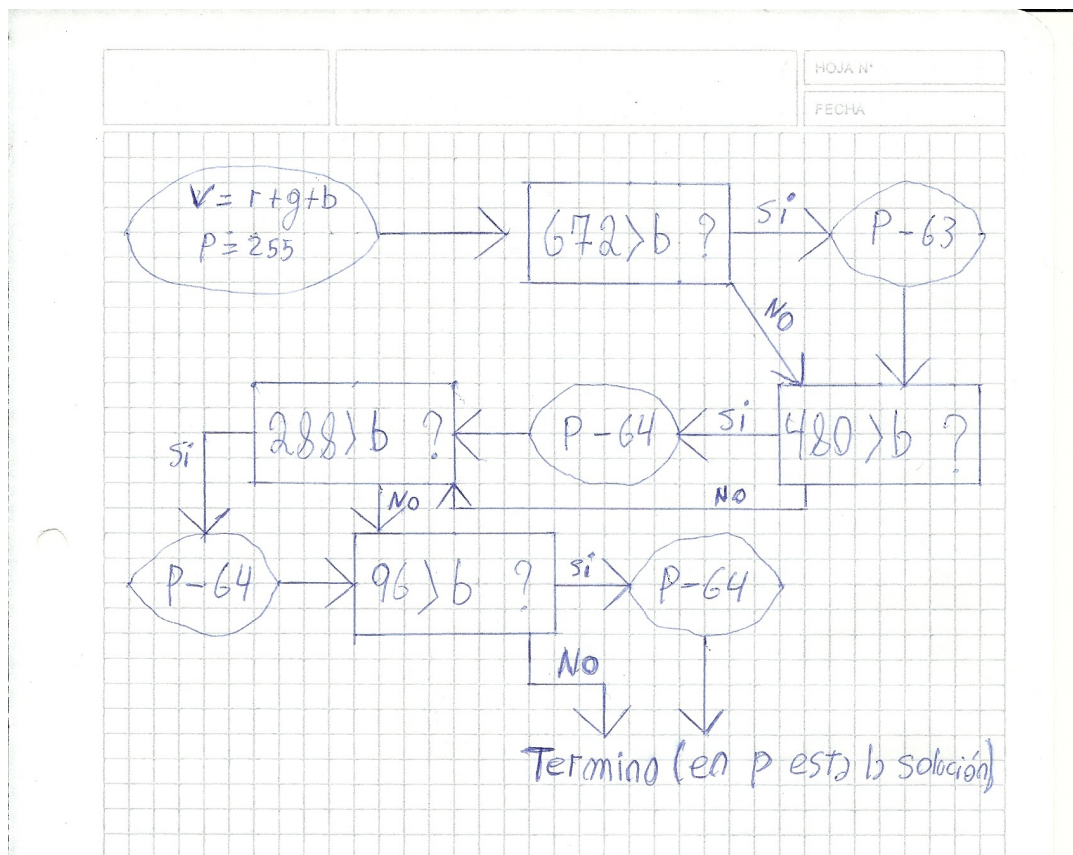
Tal vez en este caso la diferencia es menos marcada porque ya se le estaba dando un uso exhaustivo a la ALU y agregar más operaciones aritméticas resulta más costoso aquí que en el caso del cropflip, donde la ALU no era mayormente utilizada.

6. Bandas

6.1. Idea general del algoritmo

Para el algoritmo de bandas se nos presenta otro desafío: debemos tomar los tres colores de la imagen (r, g, b), sumarlos, y luego comparar cada uno de ellos para ver si se encuentra en un rango determinado. Para resolver la primera problemática usaremos las instrucciones *phaddw*, que nos permitirá a través de una suma horizontal, sumar los valores r, g, b de manera cómoda solamente utilizando dos registros. El segundo problema será comparar estos valores obtenidos en la suma de una manera eficiente. Queríamos compararlos todos a la vez y a partir de esas comparaciones determinar que valores deberá ir en cada píxel. Esta se resolverá utilizando broadcasting. El algoritmo irá comparando en cada paso contra un valor y en caso de cumplirse una condición, restará donde corresponda.

Como primer paso, leemos los 4 píxeles y los guardamos en un xmm. Luego, desempaquetamos los datos de byte a word para poder realizar la suma de las componentes de cada píxel sin salirnos de la representación. La suma se hace a través de dos instrucciones de suma horizontal, como mencionamos anteriormente, de tal manera que nos quedan los b de cada píxel en las cuatro words de la parte baja de un xmm. A continuación realizamos unas comparaciones utilizando máscaras predefinidas para determinar el valor que tendrá cada píxel en cada una de sus componentes. Después de realizadas estas comparaciones, nos queda en las word de la parte baja de un xmm los 4 valores que se asignarán a cada componente de cada píxel. Luego, empaquetamos estos valores pasandolos de word a byte y aplicamos un shuffle que los deja en el los lugares que corresponden para finalmente copiarlos al destino.




- En la sección data tenemos mascarar y constantes broadcasteadas que utilizaremos para hacer las comparaciones.
- Además en esta sección tenemos una doble qword la cual usaremos para el shuffle final.
- Previo al ciclo donde procesamos los píxeles, movemos estos datos a registros xmm.
- Ya una vez dentro del ciclo, leemos 4 píxeles y los guardamos en un xmm.

- Desempaquetamos los bytes a word para poder hacer la suma de las componentes de cada píxel sin irnos de la representación.
- Hacemos dos sumas horizontales para obtener los cuatro valores de b.
- Luego utilizamos las mascaras para comparar en paralelo cada píxel con el b correspondiente y asignando el valor de rgb segun corresponda.
- Nos queda en cada word de la parte baja de un xmm, los 4 valores que se asignaran a cada rgb de cada píxel.
- Finalmente, empaquetamos estos valores para volver a byte y los shuffleamos para dejarlos en los lugares correspondiente y lo asignamos en el destino.

6.2. Diferencias de performance en Bandas

Los resultados de los tiempos comparativos son los siguientes:



6.2.1. Resultados

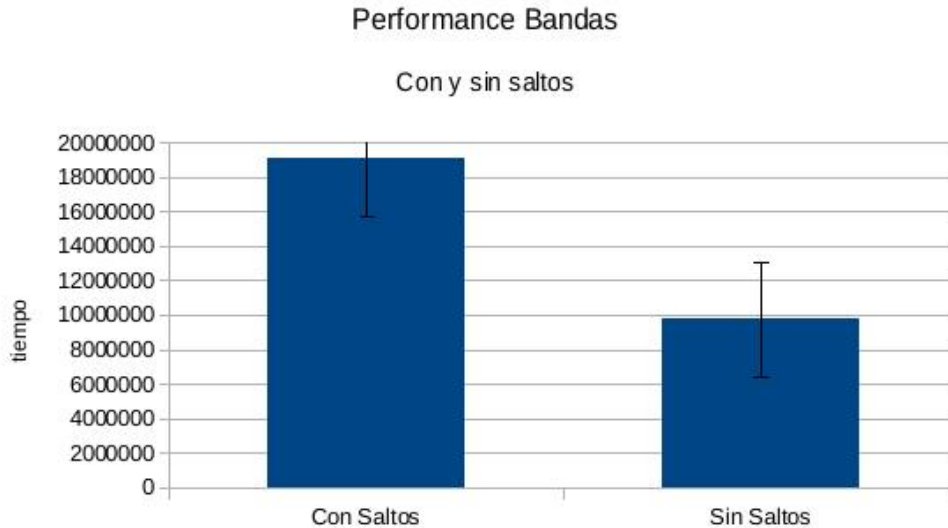
Otra vez puede observarse que en promedio el algoritmo en assembler que se vale de instrucciones vectoriales es superior a su contraparte en C. Incluso con el mayor grado de optimización nuestro algoritmo logra ser casi un 50 % mejor que el código en C con mayor grado de optimización. Para esta escala el desvío estándar no es apreciable ya que es un orden de magnitud menor.

6.2.2. Conclusiones

Nuevamente podemos concluir que resulta ventajoso utilizar instrucciones vectoriales para realizar cálculos paralelizados sobre un gran volumen de datos.

6.3. Saltos condicionales

En este experimento veremos como afectan los saltos condicionales a la performance del código C compilado con -O1. Para ello lo que haremos es quitar los IFs del código dejando solo una banda, luego medir la performance y compararla con la versión con saltos.



6.3.1. Resultados

En el gráfico puede observarse una gran diferencia entre el código que tiene saltos condicionales y el código que no los tiene. La varianza también es levemente diferente, 301534 del código con saltos a 109026 sin los mismos.

6.3.2. Conclusiones

La variación de tiempos ocurre posiblemente debido a que en el caso del código con saltos, el procesador intentará predecir el salto, conocido como branch prediction, tomando todas las posibles ramas de la ejecución. Esto sin duda causará que el procesador esté más ocupado realizando cálculos en todas las ramas y aumente el tiempo de ejecución. Esto también explicaría el aumento en la variabilidad, ya que el CPU se vuelve menos predecible.

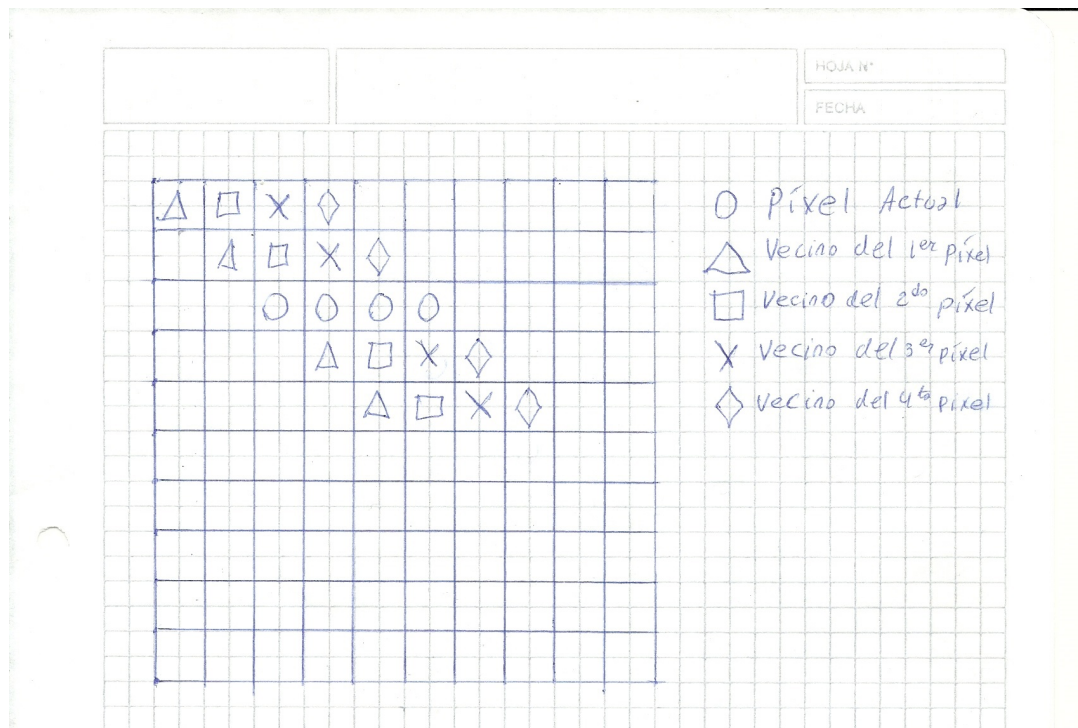
6.4. Motion Blur

6.5. Idea general del algoritmo

La idea de este algoritmo es, por cada píxel del destino se deben tomar 5 píxels de la entrada, se multiplica cada uno de los colores por 0,2 y luego se los suma. Lo que realmente haremos en el algoritmo será primero hacer la suma y luego multiplicar por 0,2 ya que esto requiere menos registros XMM. Para ello debemos tener cuidado de tomar correctamente los casos borde y no aplicar motion blur donde no corresponde.

Una idea general de cómo funciona el algoritmo en assembler es la siguiente:

Al comenzar el ciclo, esta vez no sólo leeremos 4 píxels, sino que también leeremos píxeles de las filas vecinas ya que para procesar un píxel (i, j) necesitaremos además los 4 píxels de las filas $i - 2$, $i - 1$, $i + 1$ e $i + 2$ en las columnas $j - 2$, $j - 1$, j , $j + 1$ y $j + 2$, respectivamente. Luego, desempaquetamos todo a word para realizar la sumas sin irnos de la representación. Cuando ya hemos sumado lo que necesitamos, desempaquetamos nuevamente pero ahora a dword para poder convertir a punto flotante y así luego multiplicar por 0,2. Una vez realizada la multiplicación, convertimos a entero nuevamente y empaquetamos todo de dword a word, y de word a byte. Finalmente, copiamos los 4 píxels procesados al destino. Además de todo esto, cada vez que terminamos de recorrer una fila, ponemos en negro los siguientes 4 píxels, y las dos primeras y últimas filas las ponemos en negro aparte, fuera del ciclo.




- Tenemos, en la sección datos, el valor 0,2 broadcasteado que utilizaremos para realizar la multiplicación.
- Previo al procesamiento de datos, guardamos en un xmm este valor.
- Dentro del ciclo, para procesar el píxel (i, j) tomamos los 4 píxels de las filas $i - 2$, $i - 1$, i , $i + 1$ e $i + 2$ a partir de la columna $j - 2$, $j - 1$, j , $j + 1$ y $j + 2$, respectivamente, y almacenamos todo en registros.
- Desempaquetamos todo a word para poder hacer la suma sin desbordar.
- Luego de realizar las sumas, desempaquetamos a dwords para así poder convertir a punto flotante.
- Con la conversión ya hecha, podemos multiplicar cada valor por 0,2.
- Convertimos a entero nuevamente y empaquetamos de dword a word y de word a byte.

- Finalmente, copiamos los 4 píxels resultantes al destino.
- Cada vez que termino de recorrer una fila, pongo en negro los siguientes 4 píxels, y las dos primeras y últimas filas las pongo en negro aparte, fuera del ciclo.

6.6. Diferencias de performance en Motion Blur

Al realizar el testing se obtuvieron los siguientes resultados:



6.6.1. Resultados

Se aprecia en el gráfico que el código ASM con SIMD tiene un promedio de tiempo de ejecución aproximadamente tres veces menor a la mayor optimización de C, y varias veces menor que O0. También se observa que O1, como O2 y O3 dan promedios de tiempo muy parecidos. Las varianzas son similares y muy pequeñas.

6.6.2. Conclusiones

En este caso podemos concluir nuevamente que la opción en assembler es mejor que la opción en C que no utiliza operaciones vectoriales, incluso con el mayor grado de optimización.

7. Conclusiones y trabajo futuro

Como primera conclusión de este trabajo practico podemos decir la gran ventaja que representa la utilización de operaciones vectoriales a la hora de realizar operaciones paralelizables sobre un gran volumen de datos. Tambien podemos concluir que esto no resulta de la misma manera en el caso de transferir información de un lugar de la memoria RAM a otro, ahí, la opción de implementar código C optimizado es tan buena como la de implementarlo con SIMD, con la ventaja de que en C el código es mas facilmente mantenible y claro.

Otras conclusiones son, que la comprobación de manera empirica que el acceso a RAM presenta una mayor caída de performance que las operaciones aritmeticas. Y que el branch prediction tambien representa una mayor caída en la performance, por lo que utilizar otras opciones que no requieran saltos condicionales es una buena opción de mejorar los tiempos de un algoritmo dado.

Como trabajo futuro, una idea interesante a desarrollar, podría ser construir o plantear un compilador de C que tome la mejor parte de los compiladores actuales, esto es, las diversas optimizaciones que realiza, y las integre con SIMD. De esta manera se podría en teoría obtenerse mejores resultados que los aquí mostrados.